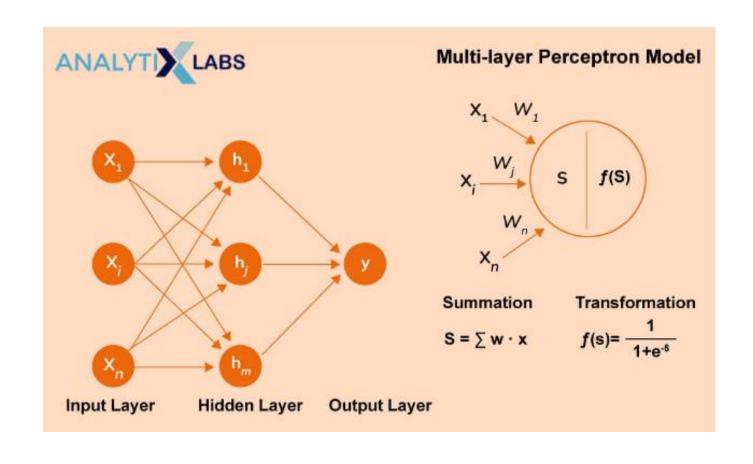
Al VIETNAM All-in-One Course (TA Session)

# EXERCISE - MULTI-LAYER PERCEPTRON



#### Review MLP

#### MLP For Regression

- Dự đoán năng lượng tiêu thụ (MPG) của xe ô tô dựa trên 9 features (thông số kỹ thuật của xe)
- Chuẩn bị data trước khi train
- Train 2 model: linear regression và MLP regression model
- So sánh kết quả

#### MLP For Classification (Non-Linearly Separable data)

- Phân loại 3 class thuộc dạng non-linearly separable dựa trên tọa độ x và y
- Train 2 model: sofmax regresion và MLP classification model
- So sánh kết quả

#### MLP For Classification (Image data)

- Phân loại loại cảm xúc của một người dựa trên ảnh đầu vào là gương mặt thể hiện cảm xúc của ngừời đó
- Chuẩn bị data trước khi train
- Train 4 models:
  - Softmax regression (không normalize)
  - Softmax regression (normalize [-1, 1])
  - MLP tanh (normalize [-1, 1])
  - MLP relu (normalize [-1, 1])
- So sánh kết quả
- Giới thiệu cơ bản về Sigmoid, Tanh, Relu

#### Modern Uses of MLPs

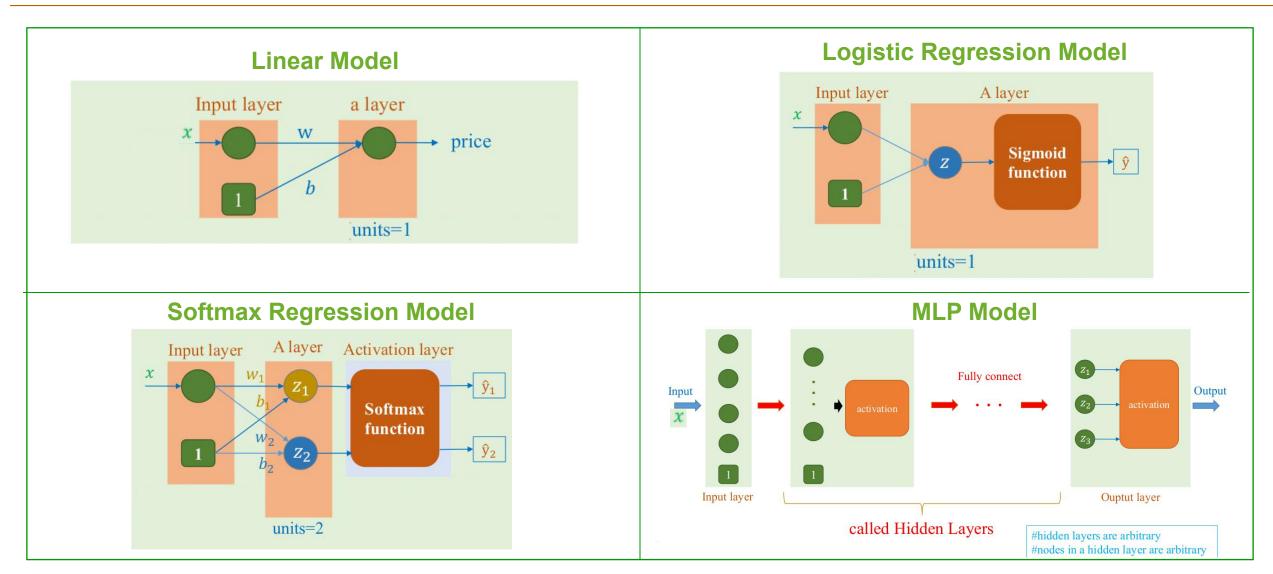
#### Review MLP

#### MLP For Regression

- Dự đoán năng lượng tiêu thụ (MPG) của xe ô tô dựa trên 9 features (thông số kỹ thuật của xe)
- Chuẩn bị data trước khi train
- Train 2 model: linear regression và MLP regression model
- So sánh kết quả

#### MLP For Classification (Non-Linearly Separable data)

- Phân loại 3 class thuộc dạng non-linearly separable dựa trên tọa độ x và y
- Train 2 model: sofmax regresion và MLP classification model
- So sánh kết quả



#### **Linear Model**

- Giải quyết bài toán về regression
- Sử dụng linear function
- Target có domain  $y \in (-\infty, +\infty)$

#### Logistic Regression Model

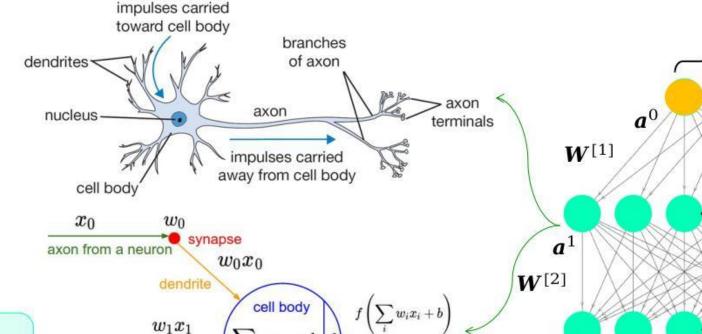
- Giải quyết bài toán về binary classification, hoặc multi-label classification
- Sử dụng linear function + sigmoid function
- Target có domain  $y \in [0,1]$

#### **Softmax Regression Model**

- Giải quyết bài toán về multi-class classification
- Sử dụng linear function + softmax function
- Target là discrete domain (thông thường được biểu diễn bằng one-hot encoding)

#### **MLP Model**

- Có thể giải quyết bài toán về **regression và classification**, ...
- Sử dụng các loại layers và các node (linear function + activation functions)
- Target có domain tùy vào bài toán



output axon

activation function

#### **Update Weights**

 $Loss = L(\widehat{y}, y)$ 

$$\boldsymbol{w}^{[l]} = \boldsymbol{w}^{[l]} - \eta \ \frac{\partial Loss}{\partial \boldsymbol{w}^{l}}$$

#### **Forward**

• 
$$a^0 = x$$

• 
$$z^{[l]} = W^{[l]T} * a^{[l-1]}$$

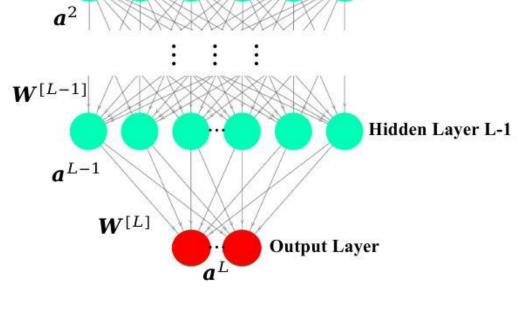
$$\bullet \ \boldsymbol{a}^{[l]} = f(\boldsymbol{z}^{[l]})$$

• 
$$\widehat{\mathbf{y}} = \mathbf{a}^{[L]} = f(\mathbf{z}^{[L]})$$
  
=  $f(\mathbf{W}^{[L]T} * f(\mathbf{W}^{[L-1]T} * \dots f(\mathbf{W}^{[2]T} * f(\mathbf{W}^{[1]T} \mathbf{x}))))$ 

#### **Backpropagation**

$$\bullet \frac{\partial Loss}{\partial \boldsymbol{w}^{[L]}} = \frac{\partial Loss}{\partial \boldsymbol{a}^{[L]}} * \frac{\partial \boldsymbol{a}^{[L]}}{\partial \boldsymbol{z}^{[L]}} * \frac{\partial \boldsymbol{z}^{[L]}}{\partial \boldsymbol{w}^{[L]}} 
\bullet \frac{\partial Loss}{\partial \boldsymbol{w}^{[1]}} = \frac{\partial Loss}{\partial \boldsymbol{a}^{[L]}} * \frac{\partial \boldsymbol{a}^{[L]}}{\partial \boldsymbol{z}^{[L]}} * \frac{\partial \boldsymbol{z}^{[L]}}{\partial \boldsymbol{a}^{[L-1]}} \dots * 
\frac{\partial \boldsymbol{a}^{[2]}}{\partial \boldsymbol{z}^{[2]}} * \frac{\partial \boldsymbol{z}^{[2]}}{\partial \boldsymbol{a}^{[1]}} * \frac{\partial \boldsymbol{a}^{[1]}}{\partial \boldsymbol{z}^{[1]}} * \frac{\partial \boldsymbol{z}^{[1]}}{\partial \boldsymbol{w}^{[1]}}$$

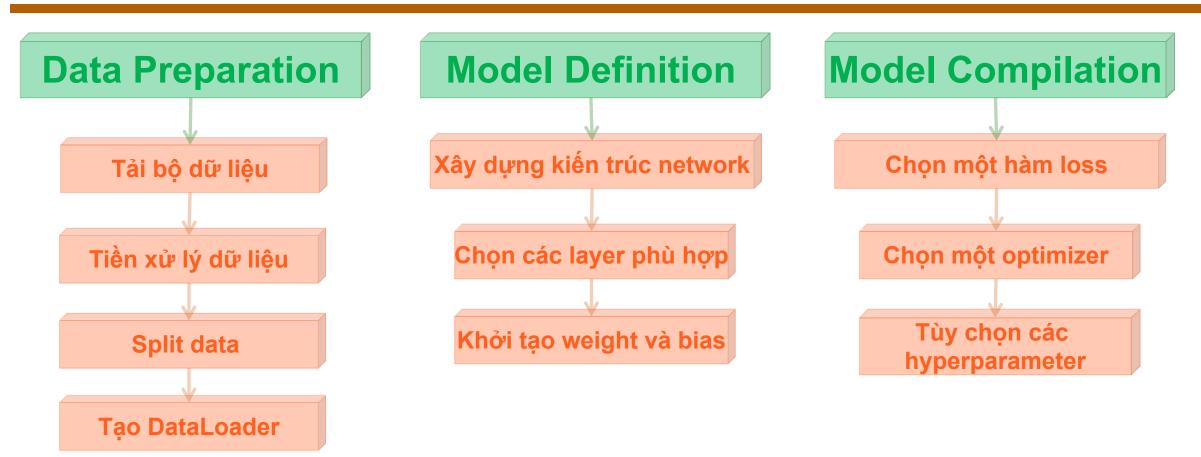
 $w_2x_2$ 



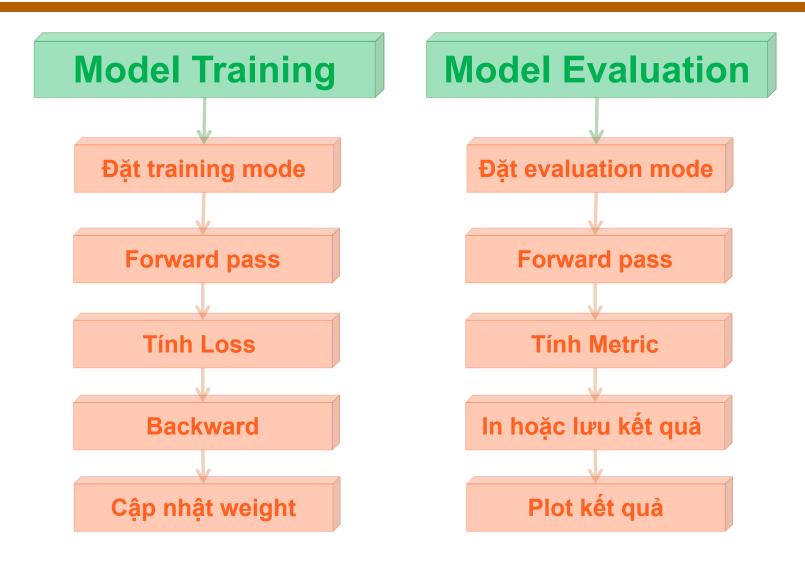
Input Layer

Hidden Layer 1

Hidden Layer 2



Các bước cơ bản trong việc build model và train khi dùng Pytorch



Các bước cơ bản trong việc build model và train khi dùng Pytorch

#### MLP For Regression

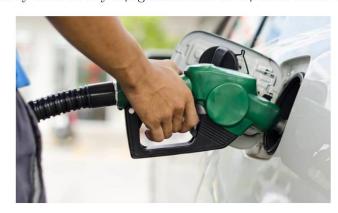
- Dự đoán năng lượng tiêu thụ (MPG) của xe ô tô dựa trên 9 features (thông số kỹ thuật của xe)
- Chuẩn bị data trước khi train
- Train 2 model: linear regression và MLP regression model
- So sánh kết quả

#### MLP For Classification (Non-Linearly Separable data)

- Phân loại 3 class thuộc dạng non-linearly separable dựa trên tọa độ x và y
- Train 2 model: sofmax regresion và MLP classification model
- So sánh kết quả

#### Yêu cầu đề bài

1. MLP FOR REGRESSION: Cho 1 tập data Auto\_MPG\_data.csv thống kê việc số lượng nhiên liệu được tiêu thụ (MPG) dựa trên 9 features của xe ô tô từ thập niên 70s đến thập niên 80s. Các bạn hãy xử lý data và xây dựng model sau để dự đoán nhiên liệu tiêu thụ của xe ô tô:



- (a) Xây dựng linear regression model: Loss = Mean Square Error, Epochs=100, Batch size=32, Optimizer = SGD, Learning rate = 0.1
- (b) Xây dựng MLP regression model: Hidden layers=2, Nodes cho mỗi layer=64, Activation cho hidden layer = ReLu, Loss = Mean Square Error, Epochs=100, Batch size=32, Optimizer = SGD. Learning rate = 0.003. Các bạn thực hiện mạng MLP như hình 15
- (c) So sánh và nhận xét kết quả giữa 2 model



Model1: Linear regression

Loss: MSE

Epochs: 100

**Optimizer**: SGD

**LR**: 0.1

Model2: MLP regression

Hidden layers: 2

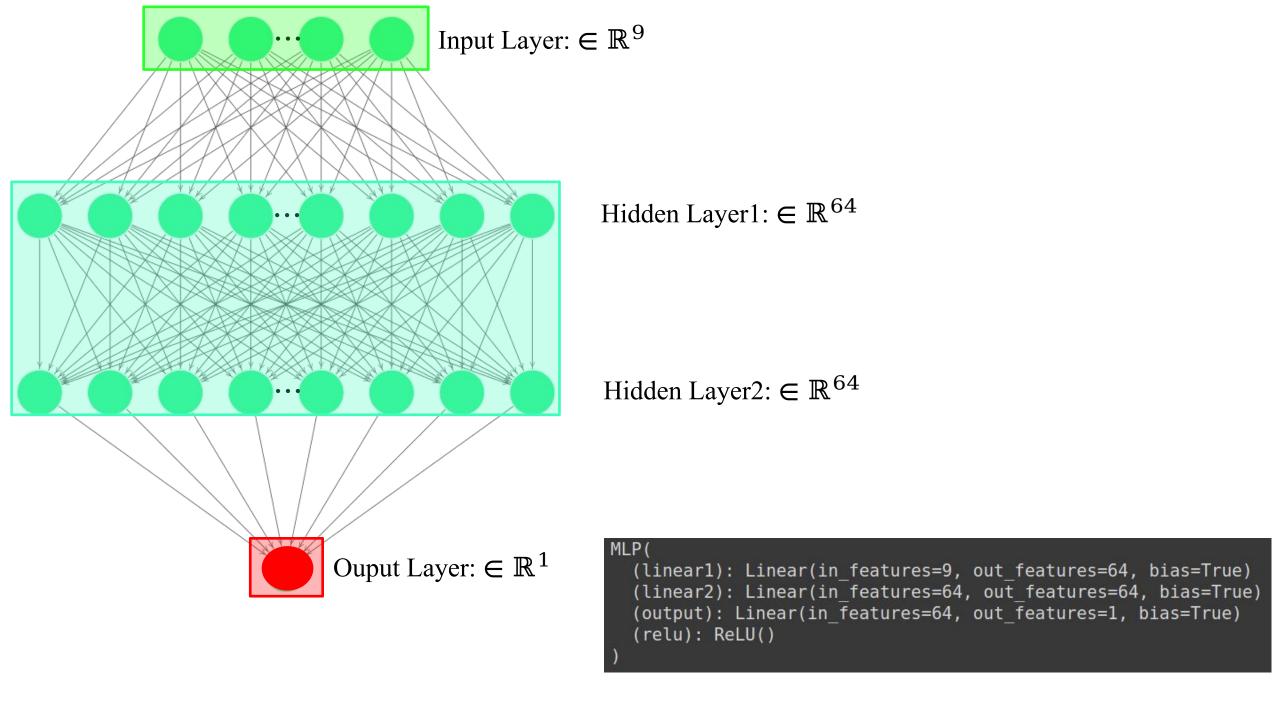
**Nodes**: 64, 64

**Activation**: relu

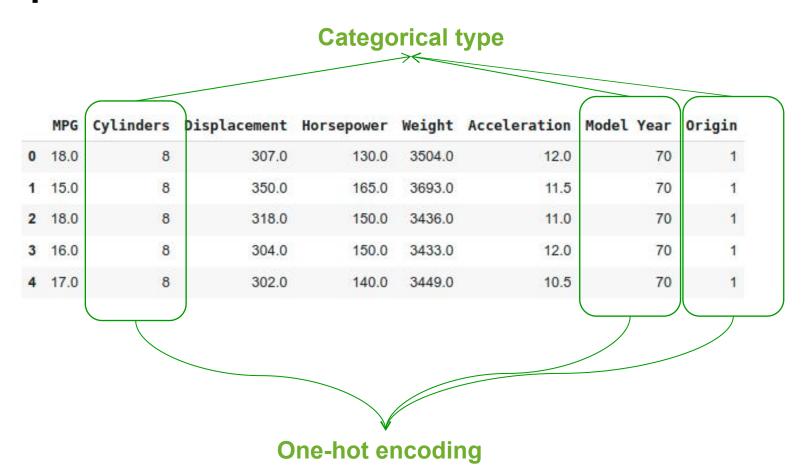
Loss: MSE

Epochs: 100

Optimizer: SGD



### • Chuẩn bị data trước khi train



Al VIETNAM All-in-One Course (TA Session)

# **MLP For Regression**

One-hot encoding

Chuẩn bị data trước khi train

	MPG	Cylinders	Displacement	Horsepower	Weight	Acceleration	Model Year	Origin
0	18.0	8	307.0	130.0	3504.0	12.0	70	1
1	15.0	8	350.0	165.0	3693.0	11.5	70	1
2	18.0	8	318.0	150.0	3436.0	11.0	70	1
3	16.0	8	304.0	150.0	3433.0	12.0	70	1
4	17.0	8	302.0	140.0	3449.0	10.5	70	1

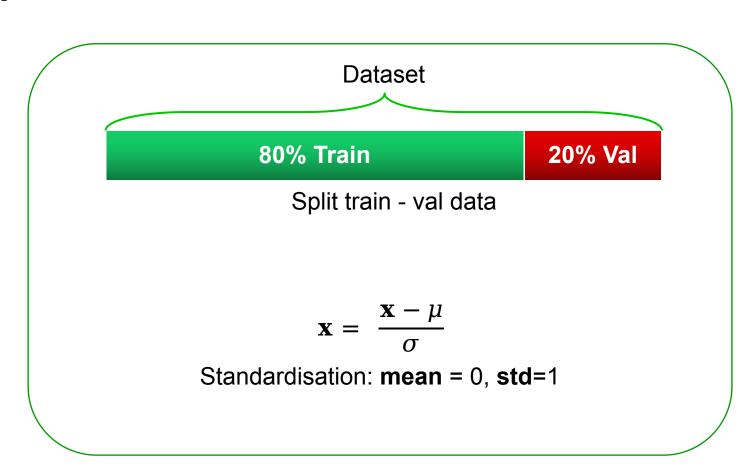
	MPG	Cylinders	Displacement	Horsepower	Weight	Acceleration	Model Year	Europe	Japan	USA
0	18.0	8	307.0	130.0	3504.0	12.0	70	0	0	1
1	15.0	8	350.0	165.0	3693.0	11.5	70	0	0	1
2	18.0	8	318.0	150.0	3436.0	11.0	70	0	0	1
3	16.0	8	304.0	150.0	3433.0	12.0	70	0	0	1
4	17.0	8	302.0	140.0	3449.0	10.5	70	0	0	1

### Chuẩn bị data trước khi train

	MPG	Cylinders	Displacement	Horsepower	Weight	Acceleration	Model	Year	Europe	Japan	USA
0	18.0	8	307.0	130.0	3504.0	12.0		70	0	0	1
1	15.0	8	350.0	165.0	3693.0	11.5		70	0	0	1
2	18.0	8	318.0	150.0	3436.0	11.0		70	0	0	1
3	16.0	8	304.0	150.0	3433.0	12.0		70	0	0	1
4	17.0	8	302.0	140.0	3449.0	10.5		70	0	0	1

Target Features

### Chuẩn bị data trước khi train



Chuẩn bị data trước khi train

0	<pre>1 dataset = pd.read_csv("/content/Auto_MPG_data.csv") 2 dataset.head()</pre>												
•		MPG	Cylinders	Displacement	Horsepower	Weight	Acceleration	Model Year	Europe	Japan	USA		
	0	18.0	8	307.0	130.0	3504.0	12.0	70	0	0	1		
	1	15.0	8	350.0	165.0	3693.0	11.5	70	0	0	1		
	2	18.0	8	318.0	150.0	3436.0	11.0	70	0	0	1		
	3	16.0	8	304.0	150.0	3433.0	12.0	70	0	0	1		
	4	17.0	8	302.0	140.0	3449.0	10.5	70	0	0	1		

### Chuẩn bị data trước khi train

**Syntax:** pd.read\_csv(filepath\_or\_buffer, sep=',', header='infer', index\_col=None, usecols=None, engine=None, skiprows=None, nrows=None)

#### Parameters:

- filepath\_or\_buffer: Location of the csv file. It accepts any string path or URL of the file.
- sep: It stands for separator, default is ', '.
- header: It accepts int, a list of int, row numbers to use as the column names, and the start of the data. If no names are passed, i.e., header=None, then, it will display the first column as 0, the second as 1, and so on.
- usecols: Retrieves only selected columns from the CSV file.
- *nrows*: Number of rows to be displayed from the dataset.
- index\_col: If None, there are no index numbers displayed along with records.
- skiprows: Skips passed rows in the new data frame.

Chuẩn bị data trước khi train



Split train - val data

```
[ ] 1 train_dataset = dataset.sample(frac=0.8, random_state=0)
2 val_dataset = dataset.drop(train_dataset.index)
```

```
[ ] 1 X_train = train_dataset.copy()
2 X_val = val_dataset.copy()
3
4 y_train = X_train.pop('MPG')
5 y_val = X_val.pop('MPG')
6
7 X_train = torch.tensor(X_train.values, dtype=torch.float32)
8 y_train = torch.tensor(y_train.values, dtype=torch.float32)
9 X_val = torch.tensor(X_val.values, dtype=torch.float32)
10 y_val = torch.tensor(y_val.values, dtype=torch.float32)
```

### Chuẩn bị data trước khi train

#### Syntax:

DataFrame.sample(n=None, frac=None, replace=False, weights=None, random\_state=None, axis=None)

#### Parameters:

n: int value, Number of random rows to generate.

frac: Float value, Returns (float value \* length of data frame values ). frac cannot be used with n.

replace: Boolean value, return sample with replacement if True.

random\_state: int value or numpy.random.RandomState, optional. if set to a particular integer, will return same rows as sample in every iteration.

axis: 0 or 'row' for Rows and 1 or 'column' for Columns.

### · Chuẩn bị data trước khi train

$$\mathbf{x} = \frac{\mathbf{x} - \mu}{\sigma} = \frac{\mathbf{x} - \frac{1}{N} \sum_{i=1}^{N} x_i}{\sqrt{\frac{1}{N} \sum_{i=1}^{N} (x_i - \mu)^2}}$$

Standardisation: mean = 0, std=1

#### **Standardisation (Z-score):**

- Là một kỹ thuật Feature Scaling đưa các giá trị của feature theo distribution có mean = 0 và standard deviation = 1.
- Giúp đưa variance của các feature về gần bằng nhau:
  - + Giá trị < 0: giá trị dưới mean
  - + Giá trị > 0: giá trị trên mean
  - + Giá trị = 0: giá trị chính là mean
- Phù hợp với các feature có ít outliers hoặc outliers không quá lớn để clipping

$$-\widehat{y} = \mathbf{w}^{T} \mathbf{x}$$

$$-\operatorname{SE} = (\widehat{y} - \mathbf{y})^{2}$$

$$-\mathbf{w} = \mathbf{w} - \eta * \frac{\partial \operatorname{SE}}{\partial \mathbf{w}}$$

	Student	CGPA	Salary '000		Student	CGPA	Salary '000
0	1	3.0	60	0	1	-1.184341	1.520013
1	2	3.0	40	1	2	-1.184341	-1.100699
2	3	4.0	40	2	3	0.416120	-1.100699

$$-\widehat{y} = 3w_1 + 60w_2 + w_0 
- SE = (3w_1 + 60w_2 + w_0 - y)^2 
- \frac{\partial SE}{\partial w} = 2 * (3w_1 + 60w_2 + w_0 - y)... 
- w = w - \eta * \frac{\partial SE}{\partial w} 
- \widehat{y} = -1.18w_1 + 1.5w_2 + w_0$$

$$-\widehat{y} = -1.18w_1 + 1.5w_2 + w_0$$

$$- SE = (-1.18w_1 + 1.52w_2 + w_0 - y)^2$$

$$- \frac{\partial SE}{\partial w} = 2 * (-1.18w_1 + 1.52w_2 + w_0 - y)...$$

$$-\mathbf{w} = \mathbf{w} - \eta * \frac{\partial SE}{\partial \mathbf{w}}$$

### Chuẩn bị data trước khi train

$$\mathbf{x} = \frac{\mathbf{x} - \boldsymbol{\mu}}{\sigma}$$

Standardisation: mean = 0, std=1

#### Chuẩn hóa dữ liệu (Data Standardisation)

```
[ ] 1 _MEAN = X_train.mean(axis=0)
2 _STD = X_train.std(axis=0)
3
4 X_train = ( X_train-_MEAN)/_STD
5 X_val = ( X_val-_MEAN)/_STD
```

#### Metric for regression

- Là việc tính toán error score để kết luận khả năng dự đoán của model trên một tập data
- Vì là bài toán regression nên không thể dùng accuracy như bài toán clasification mà thay vào đó là kết quả dự đoán gần với kết quả thật là bao nhiều
- Có 3 metric phổ biến: MSE, MAE, và R-squared

$$MAE = \frac{1}{N} \sum |\widehat{y} - y|$$

$$MSE = \frac{1}{N} \sum (\widehat{y} - y)^2$$

R-squared = 
$$1 - \frac{RSS}{TSS}$$

$$RSS = \sum (\widehat{y} - y)^2$$

$$TSS = \sum (y - \overline{y})^2$$

- MAE: Đo trị tuyệt đối sai lệch giữa kết quả dự đoán và giá trị thật. Ít bị ảnh hưởng bởi outlier hơn MSE. Nhưng có thể không phản ánh được hết tác động của outliers
- MSE: Đo bình phương độ sai lệch giữa kết quả dự đoán và giá trị thật. Độ sai lệch càng lớn khi outliers càng lớn nhưng nếu quá lớn thì sẽ chỉ chịu sự tác động của outliers
- **R-squared:** Có range [0,1], giá trị càng lớn thì thể hiện performance của model càng tốt (ko giống với MAE và MSE càng bé càng tốt). Hoạt động theo giả thuyết là ban đầu dự đoán kết quả bằng trung bình của data (R-squared = 0, RSS=TSS) sau đó nhờ huấn luyện kết quá dự đoán tốt hơn (R-squared > 0, RSS<TSS)

Al VIETNAM All-in-One Course (TA Session)

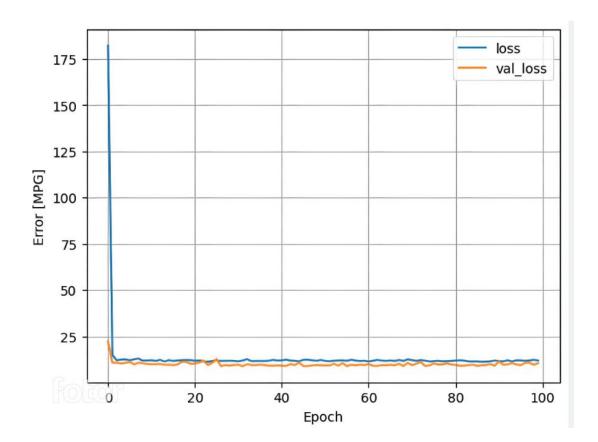
# **MLP For Regression**

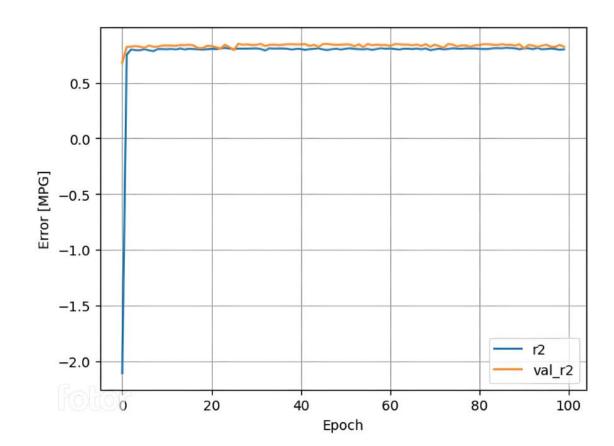
Model1: Linear regression

Loss: MSE

Epochs: 100

Optimizer: SGD





AI VIETNAM All-in-One Course (TA Session)



Model2: MLP regression

Hidden layers: 2

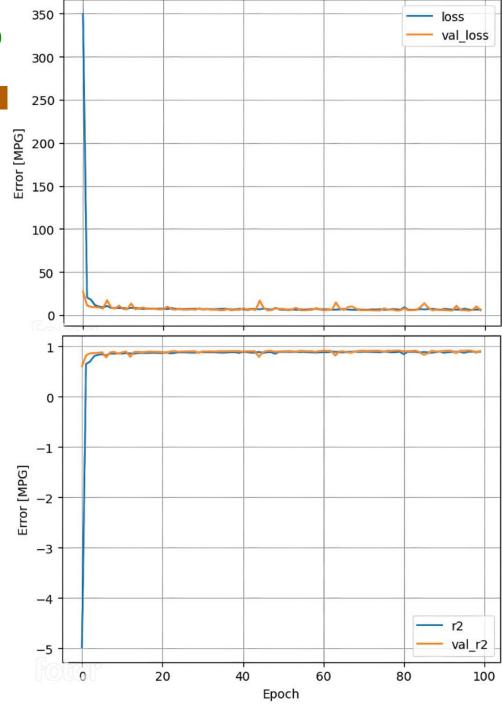
Nodes: 64, 64

Activation: relu

Loss: MSE

Epochs: 100

Optimizer: SGD



AI VIETNAM All-in-One Course (TA Session)

# **MLP For Regression**

## So sánh kết quả

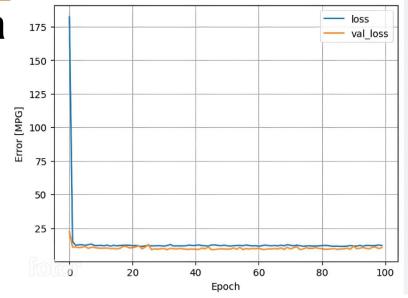
Model1: Linear regression

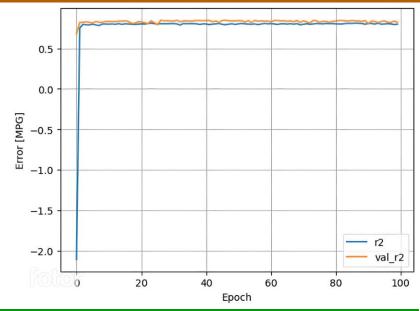
Loss: MSE

Epochs: 100

Optimizer: SGD

**LR**: 0.1







Hidden layers: 2

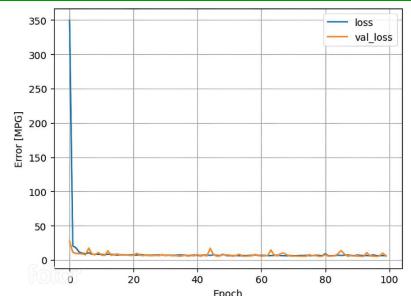
**Nodes**: 64, 64

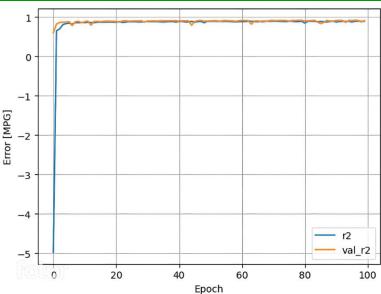
**Activation**: relu

Loss: MSE

Epochs: 100

Optimizer: SGD





Al VIETNAM All-in-One Course (TA Session)

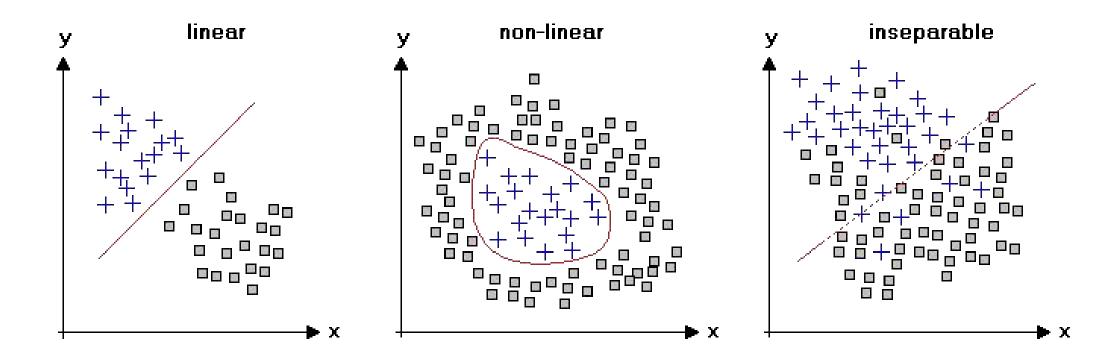
#### MLP For Regression

- Dự đoán năng lượng tiêu thụ (MPG) của xe ô tô dựa trên 9 features (thông số kỹ thuật của xe)
- Chuẩn bị data trước khi train
- Train 2 model: linear regression và MLP regression model
- So sánh kết quả

#### MLP For Classification (Non-Linearly Separable data)

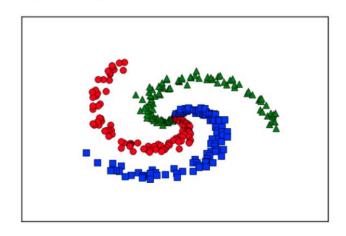
- Phân loại 3 class thuộc dạng non-linearly separable dựa trên tọa độ x và y
- Train 2 model: sofmax regresion và MLP classification model
- So sánh kết quả

• Trong bài toán phân loại thường có 3 trường hợp về data



#### Yêu cầu đề bài

2. MLP FOR CLASSIFICATION (nonlinear data) Cho 1 tập data NonLinear\_data.npy (data này không cần xử lý) là nonlinear data gồm label (có 3 class khác nhau) và 2 features (tọa độ x và y). Các bạn hãy xây dựng model sau để phân loại đúng được 3 class này:



- (a) Xây dựng softmax regression model: Loss= Cross Entropy, Metric = Accuracy, Epochs=200, Batch size=32, Optimizer=SGD, Learning rate = 0.1
- (b) Xây dựng MLP classification model: Hidden layers=1, Nodes cho mỗi layer=128, Activation cho hidden layer = ReLu, Loss = Cross Entropy, Metric = Accuracy, Epochs=500, Learning rate=0.1, Batch size = 32, Optimizer = SGD. Các bạn thực hiện mạng MLP như hình 16
- (c) So sánh và nhận xét kết quả giữa 2 model



Model1: Softmax regression

Loss: CE

Epochs: 500

Optimizer: SGD

Learning rate: 0.1

Model2: MLP Classification

Hidden layers: 1

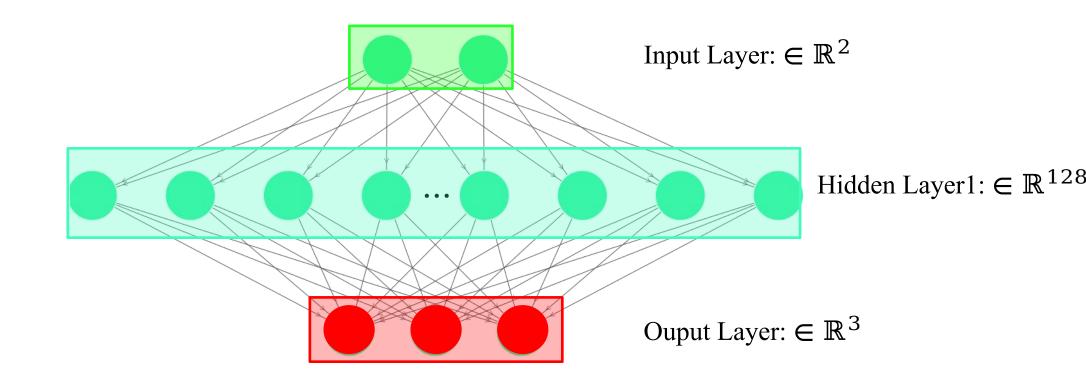
**Nodes**: 128

Activation: relu

Loss: CE

Epochs: 500

Optimizer: SGD



```
MLP(
    (linear1): Linear(in_features=2, out_features=128, bias=True)
    (output): Linear(in_features=128, out_features=3, bias=True)
    (relu): ReLU()
)
```

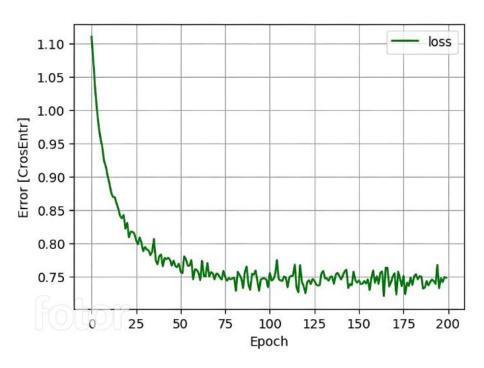
Model1: Softmax regression

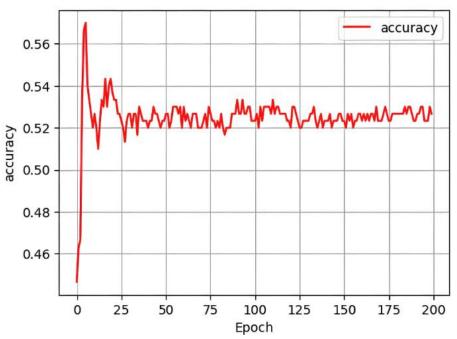
Loss: CE

Epochs: 500

Optimizer: SGD

Learning rate: 0.1





#### Model2: MLP Classification

Hidden layers: 1

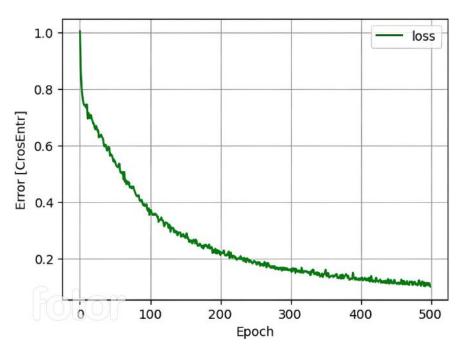
**Nodes**: 128

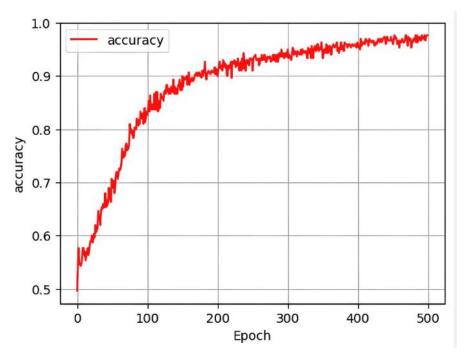
Activation: relu

Loss: CE

Epochs: 500

Optimizer: SGD





### So sánh kết quả

Model1: Softmax regression

Loss: CE

Epochs: 500

Optimizer: SGD

Learning rate: 0.1



Hidden layers: 1

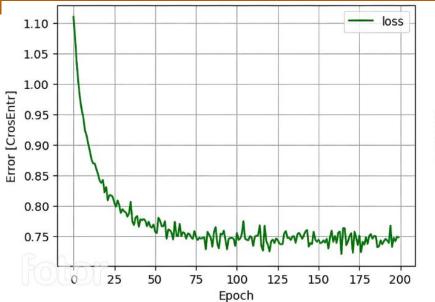
**Nodes**: 128

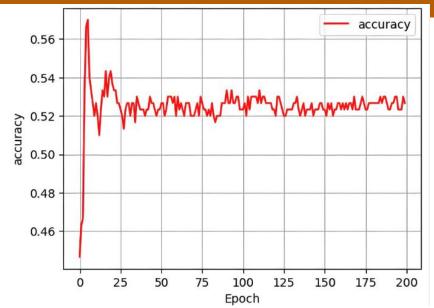
**Activation**: relu

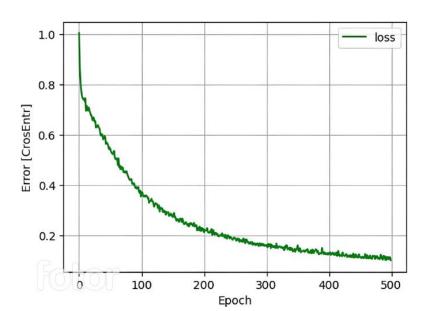
Loss: CE

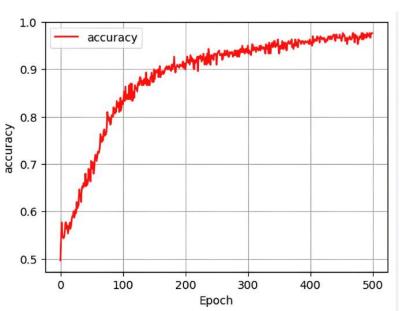
Epochs: 500

Optimizer: SGD

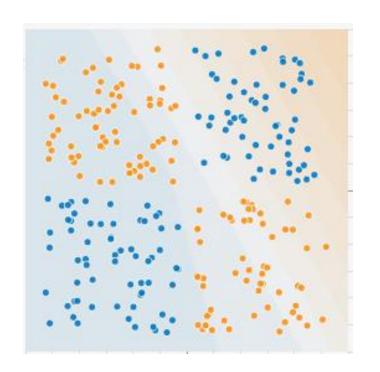


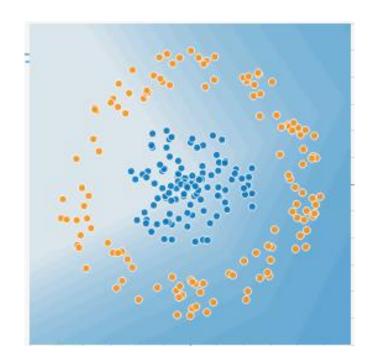






- Other Non-linearly Separable data
  - Test capacity of MLP







#### MLP For Classification (Image data)

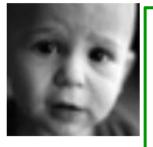
- Phân loại loại cảm xúc của một người dựa trên ảnh đầu vào là gương mặt thể hiện cảm xúc của ngừời đó
- Chuẩn bị data trước khi train
  - High-level Keras preprocessing utilities
  - Input pipeline from scratch dùng tf.data
- Train 4 models:
  - Softmax regression (không normalize)
  - Softmax regression (normalize [-1, 1])
  - MLP tanh (normalize [-1, 1])
  - MLP relu (normalize [-1, 1])
- So sánh kết quả
- Giới thiệu cơ bản về Sigmoid, Tanh, Relu

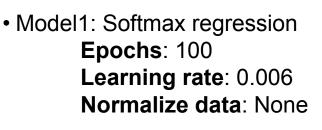
#### Yêu cầu đề bài

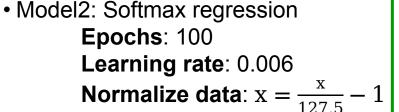
Ånh gương Class 7 trạng thái Model? măt cảm xúc







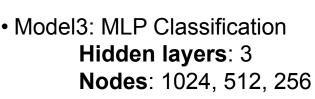












Activation: tanh Epochs: 100

Learning rate: 0.006 Normalize data:  $x = \frac{x}{127.5} - 1$   Model4: MLP Classification Hidden layers: 3

**Nodes**: 1024, 512, 256

**Activation**: relu Epochs: 100

**Learning rate**: 0.006

Normalize data:  $x = \frac{x}{127.5} - 1$ 





Ouput Layer:  $\in \mathbb{R}^7$ 

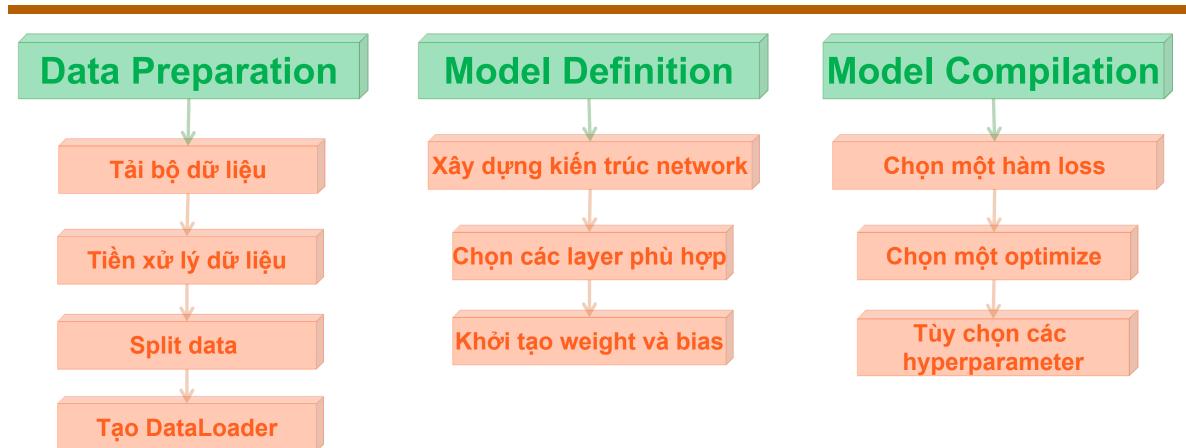
```
MLP(
   (linear1): Linear(in_features=32400, out_features=1024, bias=True)
   (linear2): Linear(in_features=1024, out_features=512, bias=True)
   (linear3): Linear(in_features=512, out_features=256, bias=True)
   (output): Linear(in_features=256, out_features=7, bias=True)
   (relu): ReLU()
)
```

· Chuẩn bị data trước khi train

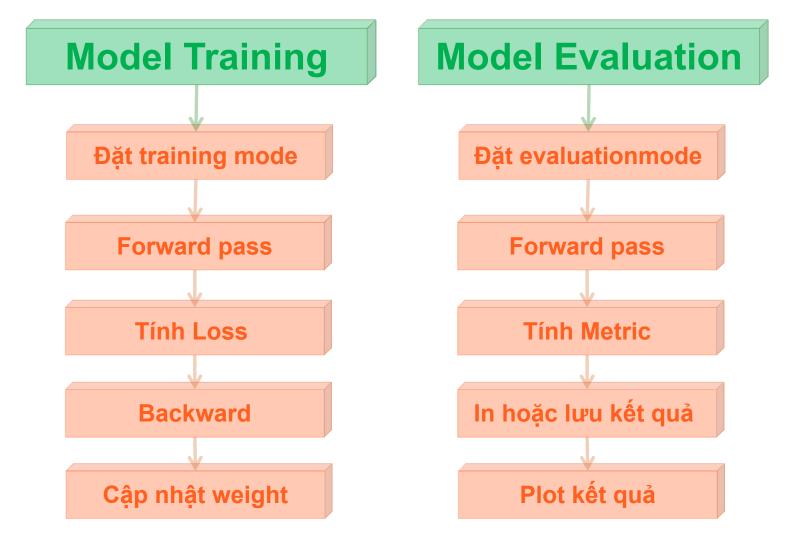
#### **Directory Tree Structure**

```
FER-2013
    test
        angry
        disgust
        happy
        neutral
        sad
        surprise
   train
        angry
        disgust
        fear
        happy
        neutral
        sad
        surprise
```

```
1 class ImageDataset(Dataset):
      def init (self, img dir, norm):
          self.resize = Resize((img_height, img_width))
           self.norm = norm
           self.img dir = img dir
           self.classes = os.listdir(img dir)
           self.image files = [(os.path.join(cls, img), cls)
                               for cls in self.classes
                               for img in os.listdir(os.path.join(img dir, cls))]
10
           self.class to idx = {cls: idx for idx, cls in enumerate(self.classes)}
11
           self.idx to class = {idx:cls for cls, idx in self.class to idx.items()}
12
13
      def len (self):
14
           return len(self.image files)
15
16
      def getitem (self, idx):
17
           img path, cls = self.image files[idx]
           image = self.resize(read image(os.path.join(self.img dir, img path)))
18
           image = image.type(torch.float32)
19
           label = self.class to idx[cls]
20
21
           if self.norm:
22
               image = (image/127.5) - 1
23
           return image, label
```



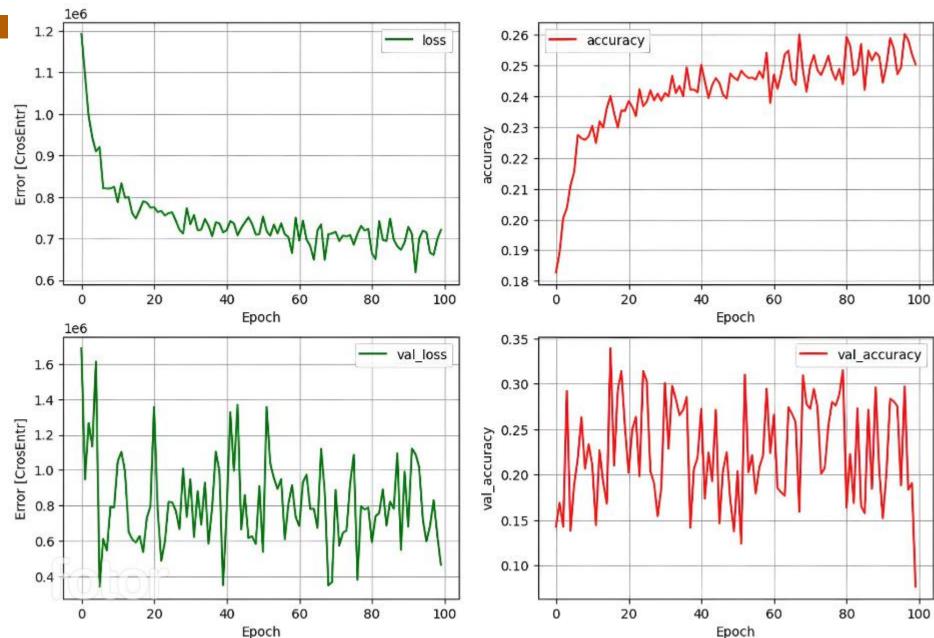
Các bước cơ bản trong việc build model và train khi dùng Pytroch



Các bước cơ bản trong việc build model và train khi dùng Pytroch

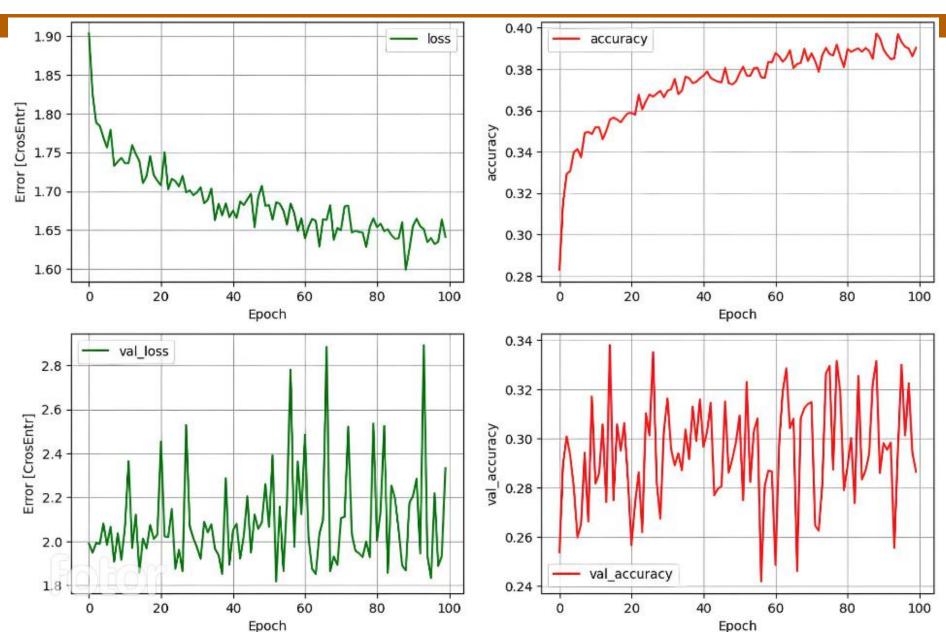
# **MLP For Classification (Image data)**

**Model1: Softmax** regression



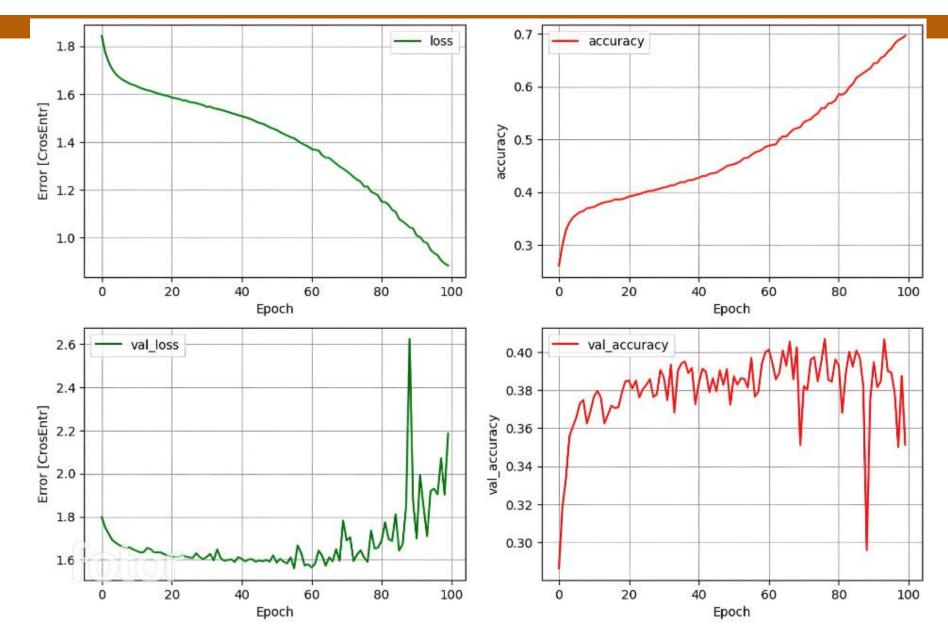
## **MLP For Classification (Image data)**

Model2: Softmax regression - Normalized



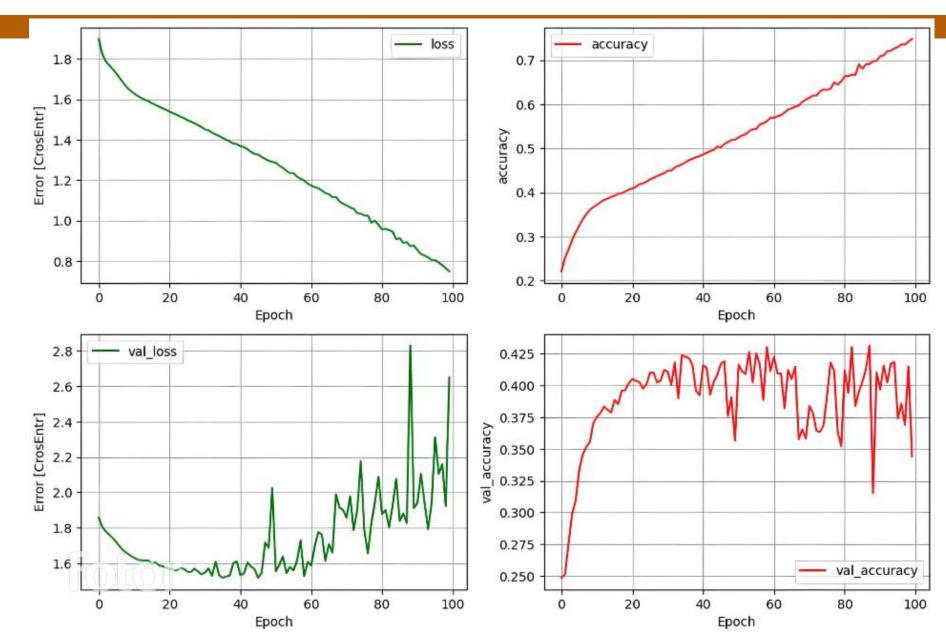
### **MLP For Classification (Image data)**

Model3: MLP - Tanh - Normalized

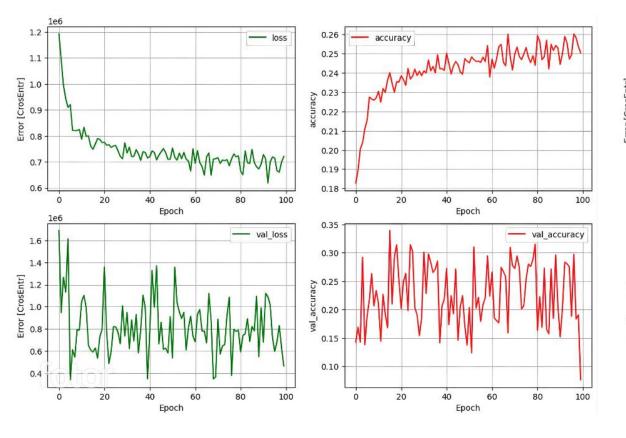


### **MLP For Classification (Image data)**

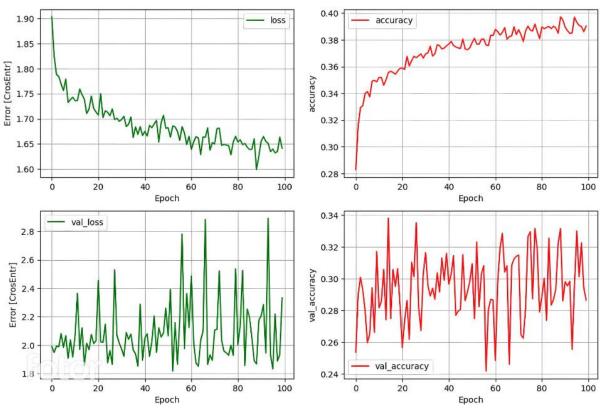
Model4: MLP -Relu -Normalized



#### **Model1: Softmax regression**

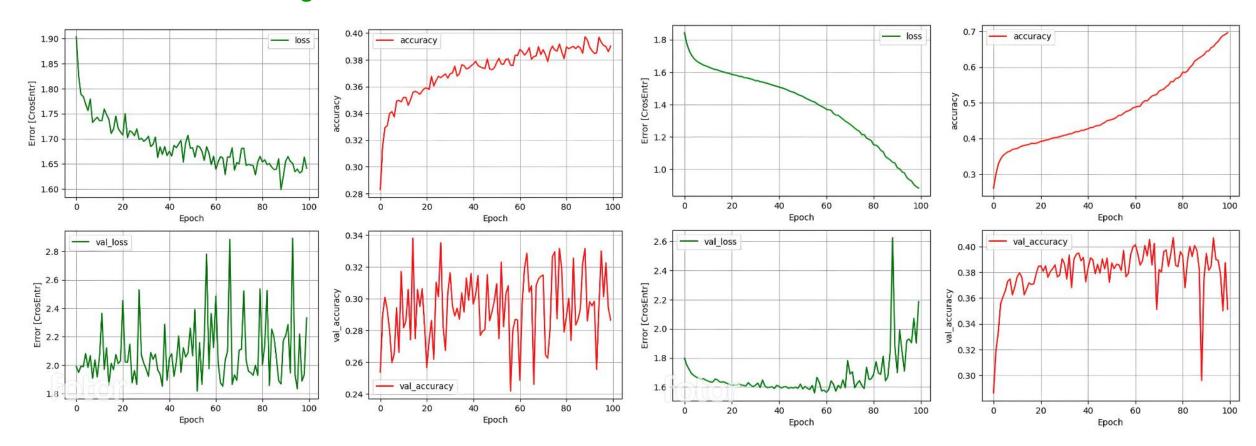


#### **Model2: Softmax regression - Normalized**

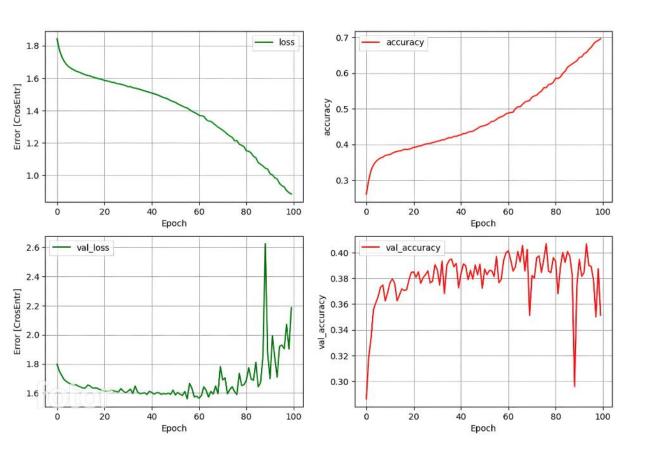


**Model2: Softmax regression - Normalized** 

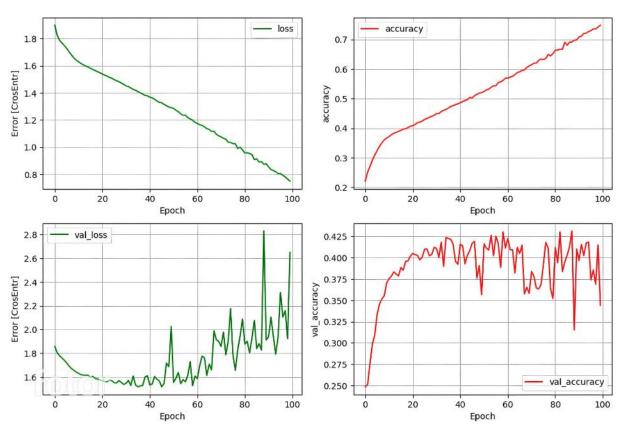
Model3: MLP - Tanh - Normalized



Model3: MLP - Tanh - Normalized

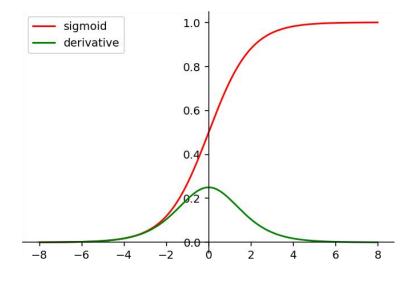


Model4: MLP - Relu - Normalized

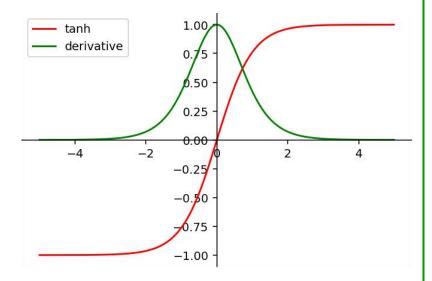


#### Activation Function: Sigmoid, Tanh, Relu

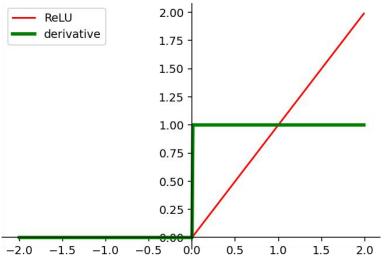
$$\operatorname{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$



$$\tanh(x) = \frac{2}{1 + e^{-2x}} - 1$$



$$ReLU(x) = \begin{cases} 0 & \text{if } x < 0 \\ x & \text{if } x \ge 0 \end{cases}$$



#### **Modern Uses of MLPs**

#### Traditional Use:

**Definition**: Multi-Layer Perceptrons (MLPs) are a class of feedforward neural networks that consist of at least three layers of nodes: an input layer, hidden layer(s), and an output layer. Each node is a neuron that uses a nonlinear activation function, typically a sigmoid or a rectified linear unit (ReLU).

**Applications**: Due to their straightforward architecture, MLPs have historically been used for simpler tasks such as basic binary or multiclass classification problems.

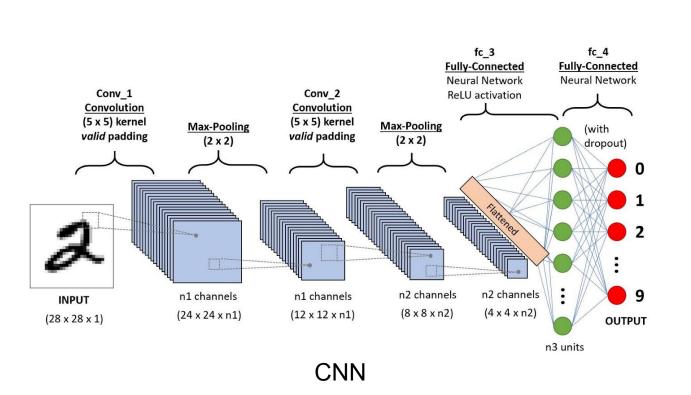
#### Modern Use:

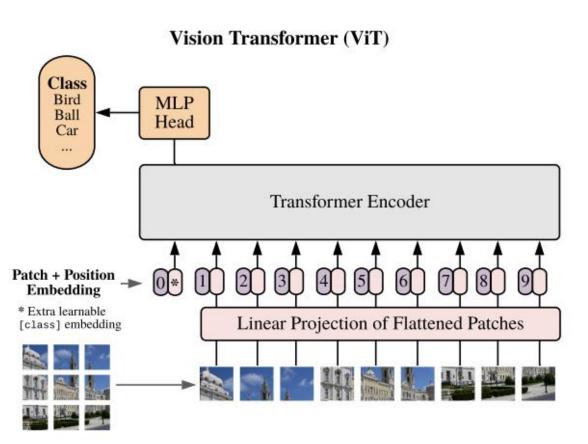
**Evolving Complexity**: As the field of artificial intelligence progressed, the usage of MLPs has evolved. They are now being integrated into more complex, cutting-edge vision models.

**Vision Transformers (ViTs)**: In Vision Transformers, MLPs are utilized within the transformer blocks, specifically in the feed-forward neural networks, aiding in learning position-wise non-linearities over the channels which is crucial for processing image data.

**MLP-Mixer**: The MLP-Mixer architecture takes this a step further by relying solely on MLPs for both mixing spatial and channel information, offering a novel approach to image classification tasks.

#### **Modern Uses of MLPs**





#### Modern Us

#### MLPs in FFNs:

**Location in Architecture**: Within each transformer block, there exists a feed-forward neural network (FFN) which comprises one or more layers of Multi-Layer Perceptrons (MLPs).

**Functionality**: The MLPs in the FFNs are responsible for learning position-wise nonlinearities over the channels. In other words, they operate independently on each position, applying a series of linear transformations interspersed with non-linear activation functions.

**Importance**: This mechanism enables the model to learn and represent complex patterns in the data, significantly contributing to the Vision Transformer's ability to understand and interpret image content.

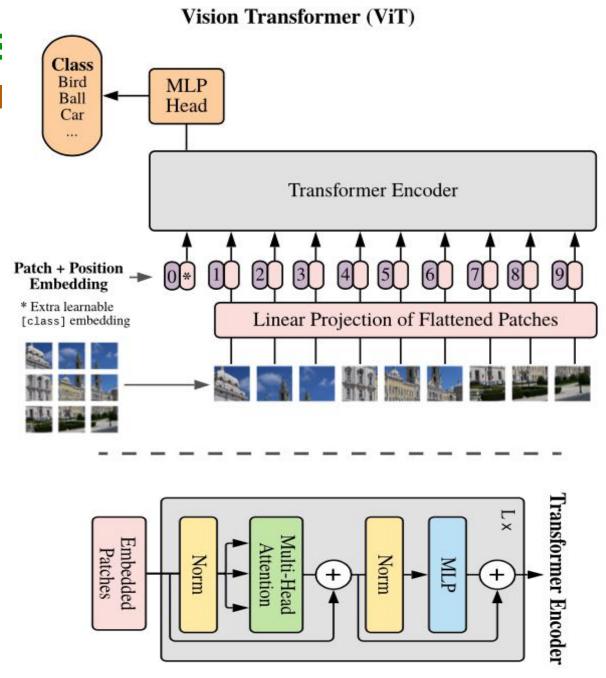


image data.

#### Modern Uses of MLPs

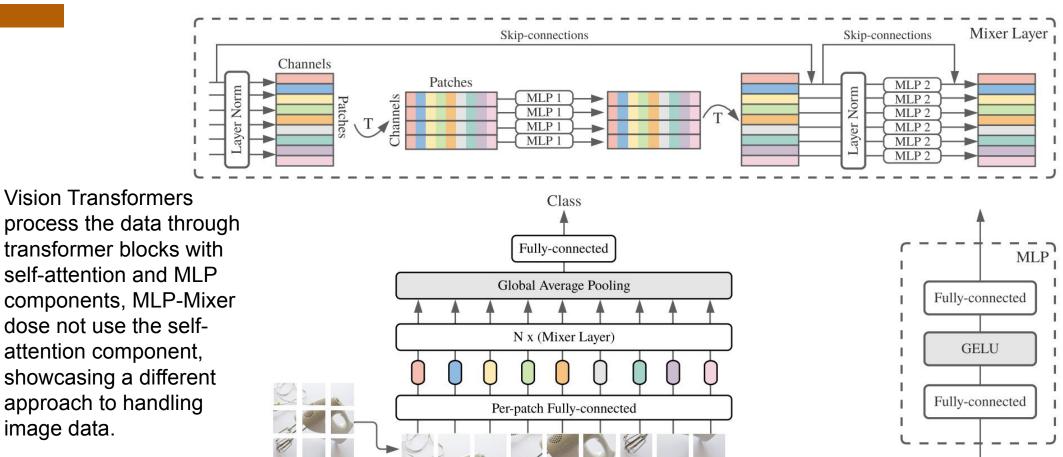


Figure 1: MLP-Mixer consists of per-patch linear embeddings, Mixer layers, and a classifier head. Mixer layers contain one token-mixing MLP and one channel-mixing MLP, each consisting of two fully-connected layers and a GELU nonlinearity. Other components include: skip-connections, dropout, and layer norm on the channels.

### **MLP Recently Research**

**Traditional to Modern Transition**: MLPs, initially employed for simpler tasks due to their straightforward architecture, have transitioned into being integral components in sophisticated vision models like Vision Transformers and MLP-Mixer.

**Architectural Innovation**: Modern vision models have leveraged MLPs in novel ways, such as in the mixing of spatial and channel information in MLP-Mixer, and within the feed-forward networks of Vision Transformers, expanding the capabilities of MLPs beyond their traditional use-cases.

#### Papers:

- Vision Transformer: An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale
- **MLP-Mixer**: An all-MLP Architecture for Vision